

Processing and Feature Extraction of ECG Signals for Arrhythmia Detection in AI Models

John M. De Moura  Ana L. Espinoza  Maria A. Flores  and Juan A. Zavaleta 

Abstract—Arrhythmias, such as tachycardia and bradycardia, are prevalent in postoperative patients, especially within the first week after surgery. These conditions can lead to significant health risks, particularly in settings with inadequate monitoring resources, such as rural areas in Peru. This paper proposes an advanced approach to arrhythmia detection using ECG signal processing and feature extraction to feed artificial intelligence (AI) models. By optimizing training data and comparing ECG signal features, this method aims to enhance the accuracy and efficiency of arrhythmia identification, thereby improving patient monitoring and reducing associated health risks.

Postoperative patients are at high risk of developing heart pathologies, which generally manifest as persistent arrhythmias, especially after the first week after surgery; conditions that might lead to significant health risks. Modern heart monitoring systems should prevent patients and their family when arrhythmias are present, thus they attend to medical assistance. This paper proposes an advanced approach to arrhythmia detection using ECG signal processing and feature extraction to feed artificial intelligence models. This method aims to enhance the accuracy and efficiency of arrhythmia detection, and thereby improving patients' monitoring systems, by optimizing training data.

Index Terms—Arrhythmia detection, artificial intelligence, ECG signal processing, feature extraction, healthcare technology, postoperative monitoring.

I. INTRODUCCIÓN

LAS arritmias, caracterizadas por alteraciones en el ritmo natural de bombeo del corazón, pueden manifestarse como taquicardia (ritmo cardíaco anormalmente rápido) o bradicardia (ritmo cardíaco anormalmente lento) [1], [2]. Estas anomalías cardíacas son más prevalentes en grupos etarios mayores y su incidencia ha aumentado en los últimos años [3]. Entre las diversas formas de arritmia, la fibrilación auricular es la más frecuente y está asociada con una alta morbilidad. En el contexto postoperatorio, entre el 35% y el 50% de los pacientes experimentan arritmias, especialmente durante la primera semana tras la cirugía [4], [5]. Aunque suelen ser transitorias, estas arritmias pueden provocar inestabilidad hemodinámica, prolongar la necesidad de soporte inotrópico y causar daños tanto a corto como a largo plazo [5]. Los procedimientos quirúrgicos con mayor incidencia de arritmias incluyen la cirugía coronaria aislada, la cirugía valvular, la cirugía combinada valvular y coronaria, y la cirugía de derivación coronaria [4]–[6]. Asimismo, las taquiarritmias auriculares son el trastorno del ritmo cardíaco más común después de la cirugía cardíaca como, por ejemplo, la fibrilación auricular postoperatoria (POAF) la cual es una complicación

común y potencialmente grave debido a que es un predictor independiente de diversos resultados adversos [7], [8]. Esta afecta aproximadamente al 35% de los pacientes sometidos a este tipo de intervenciones, alcanzando su incidencia máxima generalmente el segundo día después de la operación [8].

En el Perú, el monitoreo de arritmias postoperatorias presenta deficiencias significativas, representando un desafío considerable para la atención médica [7], [8]. Un estudio de la Universidad Cayetano Heredia reveló que solo cinco enfermeras son responsables del cuidado y monitoreo de 18 pacientes postoperatorios, lo cual limita la capacidad del personal médico debido a la falta de tiempo, sobrecarga laboral y escasez de equipos [9], [10]. Esta insuficiencia en el monitoreo constante de los pacientes resulta en el desarrollo de patologías cardíacas más graves, estancias hospitalarias prolongadas y mayores costos [9], [10].

II. PLANTEAMIENTO DEL PROBLEMA

A partir de lo expuesto podemos identificar que, particularmente en las áreas rurales, la falta de un monitoreo adecuado de arritmias cardíacas en pacientes postoperatorios incrementa el riesgo de pasar por alto complicaciones cardíacas graves y retrasa su detección, lo que conlleva a una atención médica menos eficaz y a un mayor riesgo para la salud del paciente. Para abordar esta problemática, proponemos un enfoque centrado en el procesamiento y la extracción de características de señales de electrocardiograma (ECG) para alimentar modelos de inteligencia artificial (IA) especializados en la detección de arritmias, especialmente arritmias postoperatorias para así reducir los riesgos asociados a la deficiencia en el monitoreo actual. Este proyecto tiene como objetivo mejorar la precisión y eficacia en la identificación de arritmias a través del uso de técnicas avanzadas de procesamiento de señales y aprendizaje automático. Por ende, nuestro enfoque se basará en la optimización de los datos de entrenamiento y la comparación de características de señales ECG para optimizar el rendimiento de los modelos de IA.

III. PROPUESTA SOLUCIÓN

La propuesta de solución consiste en desarrollar un sistema para el procesamiento y la extracción de características de señales ECG con el fin de detectar arritmias utilizando modelos de inteligencia artificial. Este sistema incluye varias etapas clave: filtrado de señales para eliminar ruido y preservar las características esenciales, normalización de las señales para estandarizar los datos y facilitar su análisis, y extracción de características relevantes como el intervalo R-R, HRV y la

energía de la señal. Las características extraídas se utilizarán para alimentar modelos de IA que puedan identificar patrones específicos asociados con diferentes tipos de arritmias. Además, se realizará un análisis estadístico de las medidas de variabilidad del ritmo cardíaco para validar la efectividad del sistema en la detección de arritmias. Este enfoque integral tiene como objetivo mejorar la precisión y la rapidez en la identificación de arritmias, contribuyendo a una mejor gestión de las enfermedades cardiovasculares.

A. Materiales

Para la adquisición de señales de ECG, se utilizó el kit BiTalino en una configuración bipolar inicial para adquirir la señal con bajo ruido, junto a un cable de electrodo de 3 conductores y electrodos de superficie. Para la visualización y guardado de las señales, se utilizó el software Open Signals bajo el formato .txt.

Además, para adquirir las señales de arritmias, se utilizó la base de datos de Physionet “A large scale 12-lead electrocardiogram database for arrhythmia study” [11], la cual contiene los ECG de las 12 derivaciones de 45 152 pacientes tomados en estado de reposo, que presenta múltiples ritmos comunes y afecciones cardiovasculares adicionales. Sin embargo, para el análisis de arritmias, solo se tendrá en consideración la derivación II y aVL.

B. Protocolo de adquisición

El protocolo se basará en la guía de procedimientos de toma de ECG del Servicio Gallego de Salud de España [12] y la resolución directorial 192-2022-HNHU-DG por el Ministerio de Salud (MINSA) y publicada en 25 de julio del 2022 [13], con el fin de realizar el proceso de manera no invasiva, respetando la integridad de los pacientes. El protocolo para la adquisición de ECG en estado de reposo consiste en los siguientes pasos:

- 1) Informar al paciente sobre el procedimiento enfatizando en su utilidad y solicitar su consentimiento verbal.
- 2) Preparar y verificar el correcto funcionamiento del BiTalino y su conexión a la computadora.
- 3) Posicionar a el paciente recostado sobre una camilla en decúbito supino de manera relajada y verificar que las zonas de fijación de electrodos estén limpias y sin grasa.
- 4) Obtener las derivaciones II y aVL, conectar los electrodos en LA (brazo izquierdo), LL (pierna izquierda) y RA (brazo derecho).
- 5) Activar el registro de la señal en el software del Opensignal y revisar la correcta toma de la señal durante todo el procedimiento.
- 6) Al finalizar con la adquisición de datos, desconectar los electrodos, recogerlos y descartarlos. Limpiar las zonas con especial cuidado e indicar al paciente la finalización del procedimiento.

Conforme a lo previamente establecido en el protocolo, como grupo control, se adquirió las señales de ECG de 4 alumnos de la Universidad Peruana Cayetano Heredia (2 mujeres y 2 varones) entre las edades de 20 y 22 años (Fig. 1). La participación de los alumnos fue voluntaria y todos declaran no tener alguna patología cardíaca.




Fig. 1: Señales de ECG de alumnos voluntarios en una ventana de tiempo de 10 segundos a una frecuencia de muestreo de 1000 Hz.

C. Procesamiento de la señal

- **Filtrado:** Para filtrar las señales obtenidas, se utilizó un filtro wavelet basado en las características expuestas en el artículo [14], con el propósito de eliminar el ruido presente y, a su vez, preservar las características locales de la señal de ECG. El tipo de wavelet madre utilizado fue Daubechies tipo 4 (db4) con 4 niveles de descomposición y un umbral o thresholding suave de 0.2.




Fig. 2: Señal filtrada

- **Normalización:** Posterior a la etapa de filtrado, se procedió con la normalización de la señal. El proceso de normalización se lleva a cabo mediante la identificación de los máximos y mínimos de la señal en cada latido. La fórmula a emplear se muestra en (1) obtenida del artículo [15] con el propósito de obtener una señal entre un rango de 0 y 1.

$$f(t) = f(t) - \frac{\min(t)}{\max(t) - \min(t)} \quad (1)$$

Siendo $f(t)$ la señal, $\min(t)$ el mínimo valor y $\max(t)$ el máximo valor de la señal.




Fig. 3: Señal normalizada

- *Extracción de características:* Con la organización y acondicionamiento de las señales obtenidas, se procedió a extraer características como el intervalo R-R, el cual es un parámetro determinante para una correcta segmentación de las señales ECG; además de parámetros como HRV y energía de la señal.

D. Análisis de datos

Se realizó un análisis estadístico de medidas de variabilidad del ritmo cardíaco para tres tipos distintos de arritmias y para el ritmo cardíaco normal como referencia. Las medidas evaluadas incluyeron el promedio de los intervalos RR (Mean RR), la desviación estándar de los intervalos RR (SDRR), rMSSD, NN50 y pNN50, las cuales se obtuvieron a partir de registros de ECG de sujetos con cada tipo de arritmia y de sujetos con ritmo cardíaco normal. Para cada grupo, se evaluó la normalidad de la distribución de estas medidas utilizando la prueba de Shapiro-Wilk, dando como resultado que las medidas no siguen una distribución. Posteriormente, se aplicaron los análisis no paramétricos Kruskal-Wallis y Dunn para determinar si existían diferencias significativas entre las arritmias y el ritmo normal. Estos análisis estadísticos son fundamentales para identificar y validar las medidas de HRV que presentan diferencias significativas con el fin de determinar qué medida de HRV es adecuada para poder definir patrones de decisión, los cuales serán la base para detectar automáticamente estas arritmias a partir de señales de ECG mediante la IA.

IV. RESULTADOS Y DISCUSIÓN

Respecto al análisis de datos, los resultados indican que las medidas de variabilidad del ritmo cardíaco (HRV) difieren significativamente entre los grupos de ritmo normal y los grupos de diferentes tipos de arritmias. La evaluación inicial de normalidad mediante la prueba de Shapiro-Wilk reveló que ninguna de las medidas de HRV seguía una distribución normal en los grupos analizados, lo que justificó el uso de pruebas no paramétricas como el test de Kruskal-Wallis para comparar las diferencias entre grupos. Los resultados de las pruebas de Kruskal-Wallis demostraron consistentemente diferencias significativas en todas las medidas de HRV (Mean RR, SDRR, rMSSD, NN50 y pNN50) entre los grupos de

ritmo normal y cada tipo de arritmia estudiada (Fig. X). Estos hallazgos sugieren que las arritmias afectan de manera distintiva la variabilidad del ritmo cardíaco en comparación con el ritmo cardíaco normal. Además, la prueba de Dunn para comparaciones múltiples post hoc confirmó diferencias significativas en las medidas de HRV entre los grupos de ritmo normal y cada tipo de arritmia, proporcionando un mayor detalle sobre las variaciones específicas observadas en cada medida. Estos resultados sugieren que la HRV puede servir como un indicador sensible de la presencia y tipo de arritmia, respaldando la utilidad potencial de estas medidas como biomarcadores en el desarrollo de sistemas de inteligencia artificial para la detección automática de arritmias a partir de señales de ECG. La integración de estas medidas específicas de HRV en modelos de IA podría mejorar significativamente la precisión y la eficiencia del diagnóstico y monitoreo de pacientes con diversas condiciones arrítmicas.

TABLE I: Comparación Bonferroni de Mean RR por cada grupo.

Row mean - Col mean	Fibrilacion auricular	Bradicardia	Ritmo normal
Bradicardia	7.24 0.00		
Ritmo normal	-1.19e+01 0.00	-1.19e+01 0.00	
Taquicardia	21.19 0.00	13.95 0.00	33.04 0.00

TABLE II: Comparación Bonferroni de rMSSD por cada grupo.

Row mean - Col mean	Fibrilacion auricular	Bradicardia	Ritmo normal
Bradicardia	-4.00 0.00		
Ritmo normal	22.88 0.00	26.87 0.00	
Taquicardia	27.99 0.00	31.99 0.00	5.12 0.00

TABLE III: Comparación Bonferroni de SDRR por cada grupo.

Row mean - Col mean	Fibrilacion auricular	Bradicardia	Ritmo normal
Bradicardia	-5.10 0.00		
Ritmo normal	20.82 0.00	25.91 0.00	
Taquicardia	26.77 0.00	31.87 0.00	5.96 0.00

TABLE IV: Comparación Bonferroni de pNN50 por cada grupo.

Row mean - Col mean	Fibrilacion auricular	Bradicardia	Ritmo normal
Bradicardia	5.82 0.00		
Ritmo normal	33.54 0.00	27.72 0.00	
Taquicardia	33.63 0.00	27.81 0.00	0.09 1.00

TABLE V: Comparación Bonferroni de NN50 por cada grupo.

Row mean - Col mean	Fibrilacion auricular	Bradicardia	Ritmo normal
Bradicardia	4.09 0.00		
Ritmo normal	33.38 0.00	29.29 0.00	
Taquicardia	33.16 0.00	29.07 0.00	-0.22 1.00

V. CONCLUSIONES

El estudio demuestra la utilidad de parámetros como el promedio de los intervalos RR (Mean RR), la desviación estándar de los intervalos RR (SDRR), rMSSD, NN50 y pNN50 para el entrenamiento adecuado de una IA con el objetivo de clasificar ritmos cardíacos en pacientes postoperatorios, incluyendo la bradicardia, la taquicardia sinusal, la fibrilación auricular y el ritmo normal del corazón. Sin embargo, los dos últimos parámetros (NN50 y pNN50) podrían generar complicaciones al discriminar entre el ritmo normal y la taquicardia sinusal en estos pacientes. Por lo tanto, se recomienda una consideración cuidadosa en la selección de estos parámetros y posiblemente la incorporación de características adicionales o métodos complementarios para mejorar la precisión de la clasificación. Estos hallazgos resaltan la importancia de una evaluación exhaustiva de los parámetros utilizados en los modelos de IA para asegurar un prediagnóstico confiable y preciso de los diferentes ritmos cardíacos en pacientes que han pasado por procedimientos quirúrgicos. Sin embargo, los resultados son prometedores y aseguran el desarrollo de una IA capaz de realizar un monitoreo continuo ante cualquier eventualidad de riesgo cardíaco.

AGRADECIMIENTOS

Los autores agradecen a los profesores Umbert Lewis de la Cruz y Moises Stevend Meza por el apoyo brindado a lo largo del ciclo.

REFERENCES

- [1] I. García Bolao, "Arritmia cardíaca: qué es, síntomas, tipos y tratamiento. CUN."
- [2] "Arrhythmias - What Is an Arrhythmia? | NHLBI, NIH," Mar. 2022.
- [3] J. A. Castro-Clavijo, S. Quintero, F. Valderrama, J. J. Diaztagle, J. Ortega, J. A. Castro-Clavijo, S. Quintero, F. Valderrama, J. J. Diaztagle, and J. Ortega, "Prevalencia de fibrilación auricular en pacientes hospitalizados por Medicina interna," *Revista Colombiana de Cardiología*, vol. 27, pp. 560–566, Dec. 2020. Publisher: Sociedad Colombiana de Cardiología.

- [4] G. O. González Kadashinskaia, L. M. Bello Carrasco, and D. A. Anchundia Alvia, "Cirugía cardíaca, complicaciones inmediatas post operatorias," *Revista Universidad y Sociedad*, vol. 12, pp. 293–300, June 2020.
- [5] A. R. Alconero Camarero, M. Carrera López, C. Muñoz García, I. Novo Robledo, and G. Saiz Fernández, "Análisis de las arritmias en el postoperatorio inmediato de cirugía cardiovascular," *Enfermería Intensiva*, vol. 16, pp. 110–118, July 2005. Publisher: Elsevier.
- [6] F. Enríquez and A. Jiménez, "Taquiarritmias postoperatorias en la cirugía cardíaca del adulto. Profilaxis," *Cirugía Cardiovascular*, vol. 17, pp. 259–274, Oct. 2010. Publisher: Elsevier.
- [7] G. Peretto, A. Durante, L. R. Limite, and D. Cianflone, "Postoperative arrhythmias after cardiac surgery: incidence, risk factors, and therapeutic management," *Cardiology Research and Practice*, vol. 2014, p. 615987, 2014.
- [8] J. W. Greenberg, T. S. Lancaster, R. B. Schuessler, and S. J. Melby, "Postoperative atrial fibrillation following cardiac surgery: a persistent complication," *European Journal of Cardio-Thoracic Surgery*, vol. 52, pp. 665–672, Oct. 2017.
- [9] S. D. Panta Barandiarán and B. Y. Zavaleta Uceda, *Cuidado Enfermero a personas post operadas en el Servicio de Cirugía en un Hospital de Chiclayo 2016*. PhD thesis, Feb. 2018. Accepted: 2018-02-06T21:59:41Z Publisher: Universidad Nacional Pedro Ruiz Gallo.
- [10] J. Guerrero Cobeñas, "Cuidado de enfermería al paciente postoperado inmediato," tech. rep., Universidad Peruana Cayetano Heredia, Peru, 2021.
- [11] J. Zheng, H. Guo, and H. Chu, "A large scale 12-lead electrocardiogram database for arrhythmia study."
- [12] M. d. I. Dono Díaz, J. A. Calvo Pérez, M. Vázquez Núñez, I. Rodríguez Pérez, V. Vázquez Núñez, A. Rodríguez Riveira, M. V. Arriarán Pérez, and S. M. Arias Iglesias, "PROCEDIMIENTO DE REALIZACIÓN ELECTROCARDIOGRAMA," 2020.
- [13] "Resolución Directoral N.º 192-2022-HNHU-DG."
- [14] N. Li, L. Zhu, W. Ma, Y. Wang, F. He, A. Zheng, and X. Zhang, "The Identification of ECG Signals Using WT-UKF and IPSO-SVM," *Sensors (Basel, Switzerland)*, vol. 22, p. 1962, Mar. 2022.
- [15] K. B. A. N. Gopal Reddy, A. Kumar Chillara, W. A. Hatamleh, K. D. Haouam, R. Verma, B. L. Dhevi, and H. K. Atiglah, "An Innovative Machine Learning Approach for Classifying ECG Signals in Healthcare Devices," *Journal of Healthcare Engineering*, vol. 2022, p. 7194419, 2022.



John Marshello De Moura Mendoza John Marshello de Moura Mendoza is a 7th-term Biomedical Engineering student at the Pontifical Catholic University of Peru and the Peruvian University Cayetano Heredia. He has a lot of interest in science and topics related to medicine that made him aim to improve the health sector in Peru based on engineering knowledge to improve people's quality of life



Ana Lucía Espinoza Quispe Ana Lucía Espinoza is a 7th-term student of Biomedical Engineering at the Pontifical Catholic University of Peru and the Peruvian University Cayetano Heredia. She has a strong interest in the areas of tissue engineering and the characterization of materials. Currently, she is working on the synthesis of hydrogels with hydroxypatite particles.



María Alejandra Flores Pérez María Alejandra Flores Pérez is a 7th-term student of Biomedical Engineering at the Pontifical Catholic University of Peru and the Peruvian University Cayetano Heredia. She has a strong interest in the development of health-related technology, particularly in the areas of biomechanics and tissue engineering. Her goal is to participate in projects that can improve the quality of life of the Peruvian population.



Juan Arturo Zavaleta Cavero Juan Arturo Zavaleta Cavero is a 7th-term Biomedical Engineering student with a strong interest in theoretical and practical signal processing, artificial intelligence, and the development of electrical hardware for innovative medical devices. His academic journey has been driven by a passion for integrating technology and healthcare to create solutions that enhance patient outcomes and advance medical practices, combining medical knowledge with engineering principles.